「コンピュータの舞台裏」

第2回

「業務への正規表現の応用」

2015-12-19

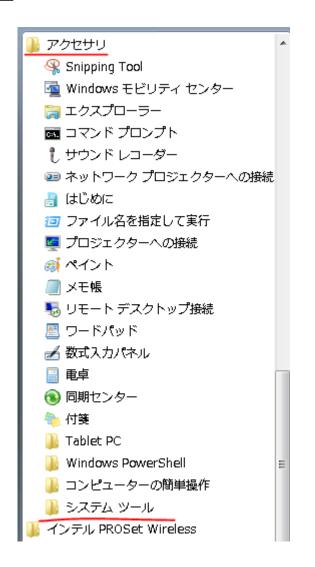
By <一へん

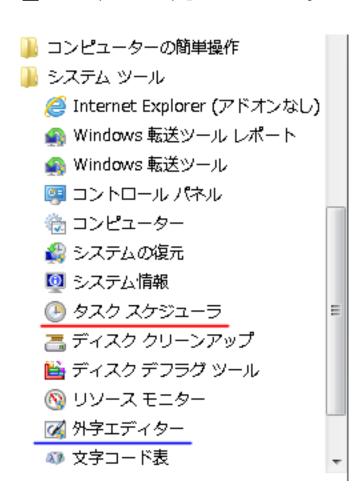
https://github.com/flhtc1964/Computer

(自己|事故)紹介

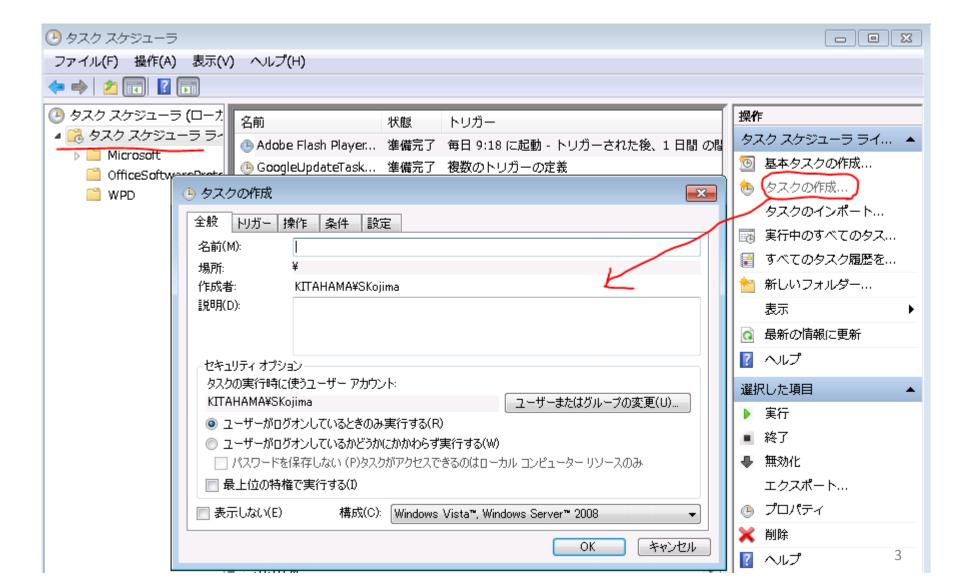
- 1964年 東京都生まれ
- N88BASIC, MSDOS, VBA, VBS, PHP, C#
- SunOS4.1.3、FreeBSDCシェル、grep、gawk、sed、Perl
- UUCP、NetNews、kermit
- 2000年 4月から大阪の某法律事務所へ転職情報システム課に所属し会社更生システム(SQL Server + Access[adp])の作成、データベース作成&メンテナンスと、主にOffice製品等のヘルプデスクを担当現在に至る

定型業務を自動化するには? 【タスクスケジュラ】で定期的に実行

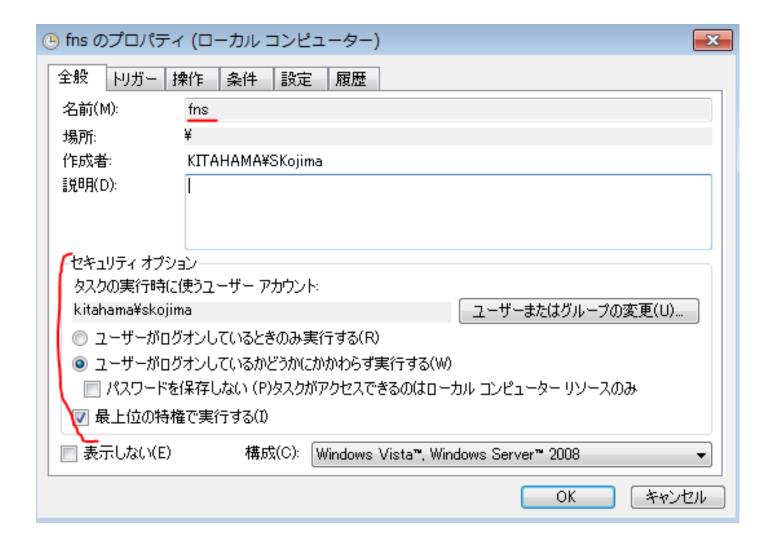




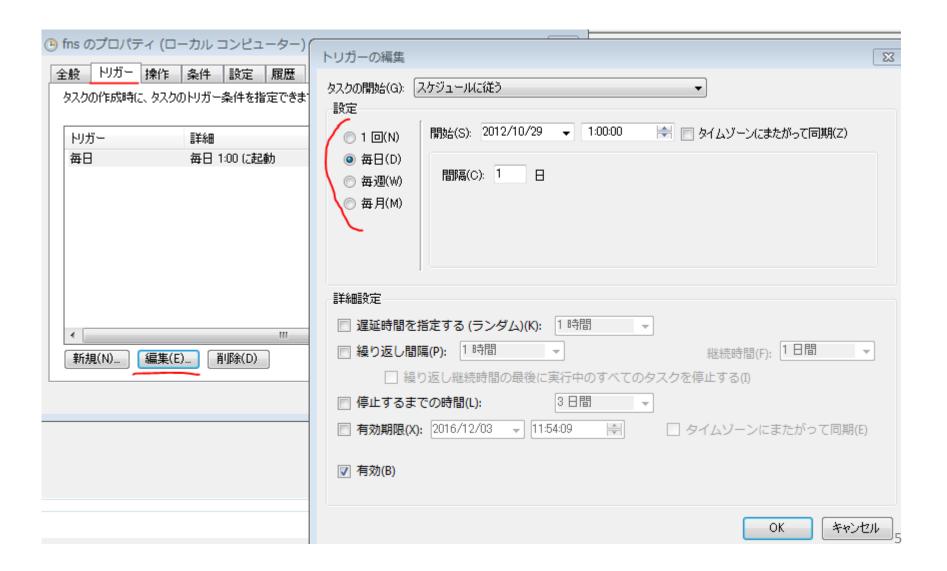
タスクの作成



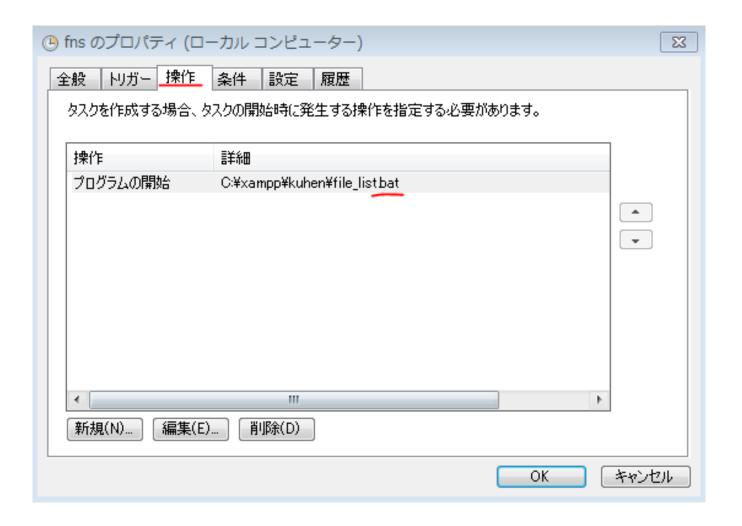
実行ユーザ名とパスワードを指定



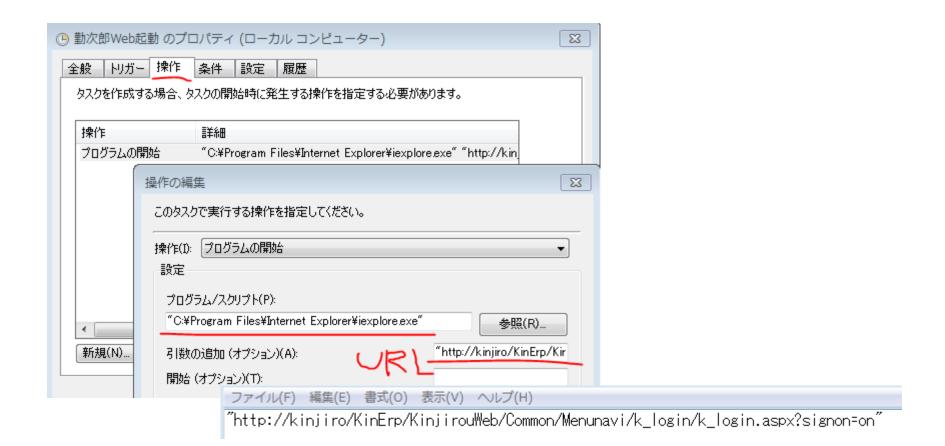
トリガー(実行時間を指定)



例えば、BATファイルを実行



例えば、決められたURLを起動



7

BAT(バッチ)ファイルのおさらい

- 「対話形式」でコマンドを入力し処理する ルーチンワーク(定型業務)を 事前にテキストファイルへ記述しておいて 必要な時に実行させる処理方法
- テキストファイル形式の拡張子は「. BAT」 #小文字で「.bat」でも可能

【注意】 Windowsの拡張子が非表示だと 見た目はfoo.batだが 実際はfoo.bat.txtに注意!

MS-DOSなら \rightarrow 「コマンドプロンプト」 【 Unixなら \rightarrow 「sh(シェル)」 】

• 対話形式でコマンドを入力して処理する道具

「リダイレクト→ く 」 手入力せずファイルで入力 sort コマンドの利用

「リダイレクト→ > 」 新規ファイル作成

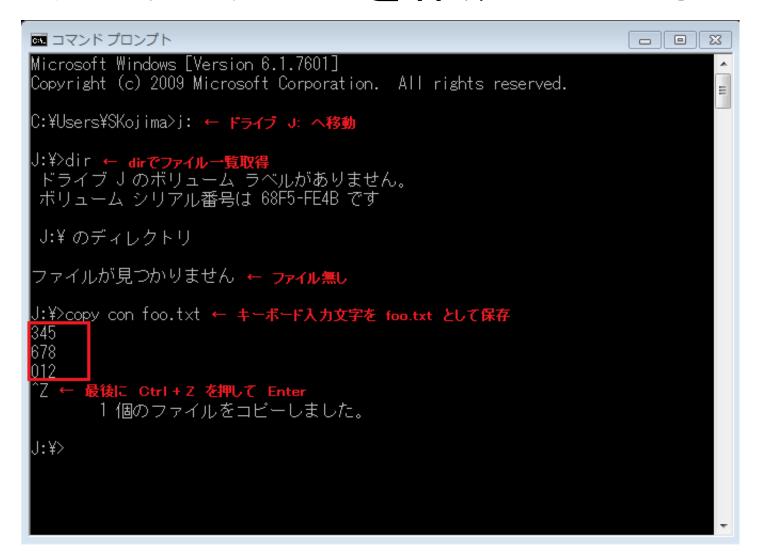
「リダイレクト→ > >」 ファイルへ追加

「パイプ→ 」 フィルター

また時間がある時に各自でお試し下さい

- ・次の頁からDOSプロンプトの使い方を説明します
- 実際に実行していくと時間が無いので説明後 実際にパソコン内の指定フォルダを使い HTML形式の検索結果を作成&表示させます
- ブラウザーによってフォルダのリンクを開くことが出来ない場合がありますので、今回はIEを使ってデモをします

コマンドプロンプトでテキスト型データファイルを作成してみる

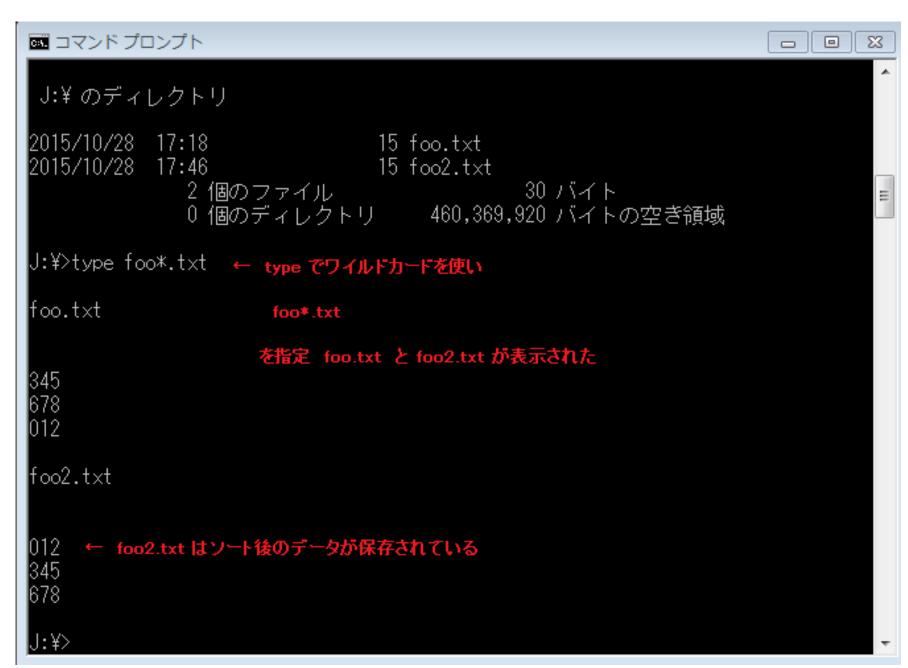


「リダイレクト→ < 」ファイルをプログラムに渡す sort コマンドの利用

```
| コマンド プロンプト
                                                  _ <u>-</u>
012
     1 個のファイルをコピーしました。← 1個のファイルが作成された
J:¥>dir ← 再度 dir でファイル一覧取得
ドライブ Jのボリューム ラベルがありません。
ボリューム シリアル番号は 68F5-FE4B です
J:¥ のディレクトリ
             15 foo.txt ← foo.txt が作成されている
1 個のファイル 15 バイト
0 個のディレクトリ 460,369,920 バイトの空き領域
                                 15 バイト
J:¥>type foo.txt ← type で中身を確認
J:¥>sort < foo.txt ← sortに対して foo.txtの中身をリダイレクト(データを送り込む)
        順序が昇順になって【 表示 】 された
```

sort < foo.txt > foo2.txt 「リダイレクト→ > 」ソート結果を新規ファイルとして保存

```
■ コマンド プロンプト
                                                   - 0
IJ:¥>sort < foo.txt
l012.
345
678
J:¥>type foo.txt ← foo.txt の中身を確認
|345|
678
           ← 中身はソートされておらず元の並び
l012.
J:¥>sort < foo.txt > foo2.txt ← それなら sort した結果【 sort <foo.txt 】を
              リダイレクトを使い > foo2.txt として保存(書出し)を実行
J:¥>dir
ドライブ 上のボリューム ラベルがありません。
ボリューム シリアル番号は 68F5-FE4B です
J:¥ のディレクトリ
2015/10/28 17:46
          :46 15 foo2.txt ← foo2.txt が新規作成されている
2 個のファイル 30 バイト
          0 個のディレクトリ 460,369,920 バイトの空き領域
```



```
■ コマンド プロンプト
                                                       lfoo2.txt
012
|345|
l678.
J:¥>copy foo*.txt foo3.txt ← コピーしろ
lfoo.txt
                     foo*.txt にマッチするファイルをまとめた後
lfoo2.txt
                     foo3.txt として作成
    1 個のファイルをコビーしました。
J:¥>dir
 ドライブ ナのボリューム ラベルがありません。
ボリューム シリアル番号は 68F5-FE4B です
J:¥ のディレクトリ
15 foo.txt
2015/10/28 17:46 15 foo2.txt
2015/10/28 18:08
             31 foo3.txt ← foo3.txt が作成された
          3 個のファイル 61 バイト
0 個のディレクトリ 460,369,920 バイトの空き領域
```

```
國 コマンド プロンプト
                                                  J:¥>type foo3.txt ← foo3.txt の中身を確認
345
678
012
012
345
678
J:¥>copy foo2.txt + foo.txt foo4.txt ← 結合するファイルの順番を + で指定する
foo2.txt
lfoo.txt
     1 個のファイルをコビーしました。
J:¥>dir
ドライブ 上のボリューム ラベルがありません。
ボリューム シリアル番号は 68F5-FE4B です
J:¥ のディレクトリ
2015/10/28 18:08
                      15 foo.txt
15 foo2.txt
2015/10/28 18:08
                       31 foo3.txt
             31 foo4.txt ← foo4.txt が作成された
92 バイト
          4 個のファイル
          0 個のディレクトリ 460,369,920 バイトの空き領域
```

```
■ コマンド プロンプト
                                                     foo.txt
     1 個のファイルをコビーしました。
J:¥>dir
ドライブ ナのボリューム ラベルがありません。
ボリューム シリアル番号は 68F5-FE4B です
J:¥ のディレクトリ
15 foo.txt
2015/10/28 17:46
                      15 foo2.txt
2015/10/28 18:08
            31 foo3.txt
             31 foo4.txt
4 個のファイル 92 バイト
0 個のディレクトリ 460,369,920 バイトの空き領域
J:¥>type foo4.txt ← foo4.txt の中身を確認
012
    ← ソートされている foo2.txt が先頭になっている
345
378
345
678
l012.
```

Dir /? コマンドヘルプを表示

■ コマンド プロ:	ンプト	X
/B	ファイル名のみを表示します(見出しや要約が付きません)。	_
7C	ファイル サイズを桁区切り表示します。これは	
	既定の設定です。/-C とすると桁区切り表示されません。	
/D	/W と同じですが、ファイルを列で並べ替えた一覧を表示します。	
/L	小文字で表示します。	
ΪŽΝ̈́	ファイル名を右端に表示する一覧形式を使用します。	
/0	ファイルを並べ替えて表示します。	
ソート順	N 名前順(アルファベット)、 S サイズ順(小さい方から)	
	E 拡張子順(アルファベット)、D 日時順(古い方から)	
l	G グループ(ディレクトリから)- 降順	
/P	1 画面ごとに停止して表示します。	
/Q	ファイルの所有者を表示します。	
/R	ファイルの代替データーストリームを表示します。	
<u>/\$</u>	指定されたディレクトリおよびそのサブディレクトリのすべての	
	ファイルを表示します。	

dir /B /S コマンドでファイル一覧

```
Microsoft Windows [Version 6.1.7601]
Copyright (c) 2009 Microsoft Corporation. All rights reserved.

C:¥Users¥SKojima>j:

J:¥>dir /B /S
J:¥foo.txt
J:¥foo2.txt
J:¥foo4.txt
J:¥foo4.txt
```

「リダイレクト→)」 dir /b /s > test.txt ファイル新規作成

```
■ コマンド プロンプト
                                                        - - X
J:¥>dir /b /s
J:¥foo.txt
J:¥foo2.txt
J:¥foo3.txt
J:¥foo4.txt
J:¥test.txt
J:¥>dir /b /s > test.txt
J:¥>dir
 ドライブ ナのボリューム ラベルがありません。
ボリューム シリアル番号は 68F5-FE4B です
J:¥ のディレクトリ
15 foo.txt
15 foo2.txt
|2015/10/28|
        18:08
                          31 foo3.txt
2015/10/28
        18:14
                          31 foo4.txt
|2015/11/06 | 12:12|
                         64 test.txt
                                     156 バイト
           5 個のファイル
```

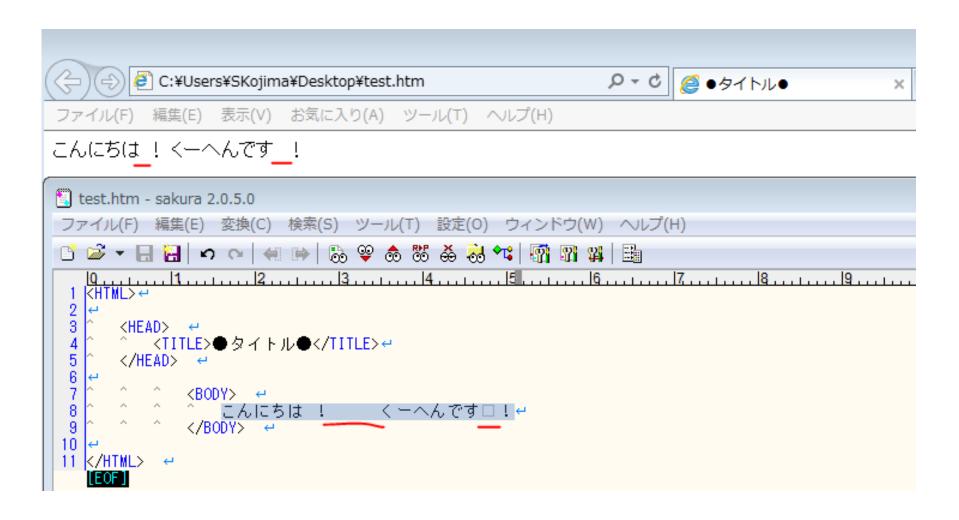
作成したtest.txtを使い最低限の HTML形式ファイルを自動作成する

```
test.htm - sakura 2.0.5.0
ファイル(F) 編集(E) 変換(C) 検索(S) ツール(T) 設定(O) ウィン
         🕶 👊 🕪 🖟 🌳 🐽 👑 🍝 🦓 🔧
 2
    <HFAD> ←
45
      <TITLE>●タイトル●</TITLE>↩
    </HEAD> ←
6
7
8
           こんにちは !
                       くーへんです□!↩
         </BODY> ←
10
```

<HTML>で始まり </HTML>で終わる

- 取りあえずメモ帳で記述可能
- くタグ>文字列クタグ>で文字を修飾例:文字の大きさ、文字の色等
- 高度になると使用する文字等指定
- くbr>タグを入れないと改行せず表示される 基本ワープロと同じく文字は連続表示
- 使用するブラウザーにより、表示や動作が 微妙に違う

半角スペースは無視される罠



Unix OS

- Windows OSが世に出る前は Unix(ユニックス)という オペレーティングシステム(OS)が動く サーバがインターネット上で複数台稼働 しており利用者はそのサーバにTelnetコマンドでサー バにログインし、sh(シェル)という 対話型のコマンドを使ってメールやNetNews そしてテキストデータ処理等を行っていた https://ja.wikipedia.org/wiki/UNIX
- Unixのsh(シェル)とは、WindowsのMS-DOSの「コマンドプロンプト」だと思ってください

正規表現 (せいきひょうげん)

- 正規表現は、Unixのお陰で一般化された
- 大量のテキストデータに対し統一した検索ルール(パターンマッチ) が必要となり

一括検索: ______ grep(egrep)

一括(検索|置換)、一括削除: sed

一括レコード単位処理: awk(gawk)

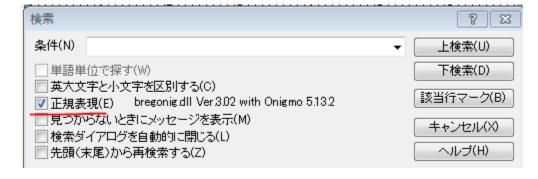
C言語、sed、awk、sh(シェル)の

機能を取り入れたプログラム言語: Perl

これらは「正規表現」を使って処理をしている

最近ではWindowsで動くエディタの検索or置換時に「正規表現」

の利用が可能



正規表現メモ

http://www.kt.rim.or.jp/~kbk/regex/regex.html

2012年8月現在の 「正規表現」使用情報

正規表現メモ

最終更新日 2012年8月24日

正規表現は使い慣れれば便利なものですが、ツールによって使える正規表現演算子(メタキャラクタ)に違いがあったりして戸惑うこともあります。そこで、正規表現を扱うツールの代表的なものを幾つか選び、そこで使われている正規表現演算子をまとめてみました。

正規表現入門者/初心者の方へ

正規表現のチュートリアルが、<u>perlの正規表現チュートリアル</u>にあります。Perl5.8のドキュメントですが、一般的な入門にも使えると思います。

Table of contents

- 1. grepで使用できる正規表現
- egrepで使用できる正規表現
- 3. sedで使用できる正規表現
- awkで使用できる正規表現
- 5. Perlで使用できる正規表現
- 6. Pythonで使用できる正規表現
- 7. Rubyで使用できる正規表現
- 8. gawk 3.0(以降)で使用できる正規表現
- 9. Tel 8.2.3(以降)で使用できる正規表現
- 10. PCREで使用できる正規表現
- 11. PHPで使用できる正規表現(mb ereg)
- 12. NET Frameworkで使用できる正規表現
- Java(1.4以降)で使用できる正規表現
- 14. POSIX 1003.2での正規表現について
- 15. 各正規表現演算子の説明
- 16. <u>各エスケーブシーケンスの説明</u>
- 17. 各処理系正規演算子一覧表
- 18. ある文字列を含まない正規表現
- 19. リンク
- 20. 用語集
- 21. 参考文献

Windowsで動く onigsed.exe(20091031版)

GNU sed 4.1.5 の日本語 Windowsへの移植(というほどたいしたことはしていない)です。 cygwinに付属のGNU sedがMBCS対応していないので作業しました。

VC++ 7.1でコンパイルしています。特にDLLは必要ありません。

また、正規表現エンジンとして鬼車(2.5.0)を組み込んでおり、オプション指定によりPerl互換の正規表現を使うことができます。で

きるだけオリジナルと同じ振る舞いをするように努力しましたが、どこかに抜けがあるかもしれません(特に改行の扱いに関して)。

漢字コードとしてshiftjis、euc-jp、utf-8が使えます。使用するときはコマンドラインオプションで

- shiftjis -Wctype=SJJIS または --ctype=SJIS (デフォルト)
- •euc-jp -Wctype=EUC または--ctype=EUC
- •utf-8 -Wctype=UTF8 または --ctype=UTF8

を指定します。マルチバイト処理をオフにしたい場合には

-Wctype=ASCII または --ctype=ASCII

を指定します。

readme.ja より抜粋

http://www.kt.rim.or.jp/~kbk/sed/



GNU sed with Oniguruma (Onigsed)とは?

正規表現エンジンとして、鬼車を組み込んだ sed です。オブション指定により、POSIX EREや Perl5互換の正規表現を使うことができます。

ダウンロードリンク

- Onigsed 2009年10月31日バージョン md5 aae0a510dee4de6acca29cc9c86ca4a5 *onigsed-20091031.zip sha1 2738e55c05883c334c66dcb264b5ab59202bf8ca onigsed-20091031.zip
- Onigsed 2009年1月1日バージョン 9728a92c58ef001984a9fed51095535f *onigsed-20090101.zip 0b93c97ba2781a44800e1d888239ac67ec54c62a5f3485196be7d757ebaaf873 *onigsed-20090101.zip
- 鬼車を使っていないバージョン(2009/10/5) md5 3fd753202cb5dbc565eeba29abd049d *sed-mbcs-win32-20091004.zip sha1 9f4f44f67cb1fa6ad9c95fa3ac232be625b36f6 sed-mbcs-win32-20091004.zip (2009/5/25)版

949ec827c9383d9ce60c947115db0cdf *sed-mbcs-win32-20090525.zip 8bdc396588ff1e978562e53fbff22e63d5703903 sed-mbcs-win32-20090525.zip

以下、readme.jaより。

・これはなに?
GNU sed 4.1.5 の日本語 Windowsへの移植(というほどたいしたことはしていない)です。cygwinに付属のGNU sedがMBCS対応していないので作業しました。VC++ 7.1でコンパイルしています。特にDLLは必要ありません。また、正規表現エンジンとして鬼車(2.5.0)を組み込んでおり、オブション指定によりPer1互換の正規表現を使うことができます。できるだけオリジナルと同じ振る舞いをするように努力しましたが、どこかに抜けがあるかもしれません(特に改行の扱いに関して)。

Onigsedで → テキストー括操作 どんなルールがあるのか「メタ文字」

- 行頭 → ^
- 行末 → \$
- 空白行 → ^\$

・該当データ削除 → /正規表現/d

onigsed.exe –e "/^\$/d" foo.txt | more

Onigsedで → テキストー括操作 どんなルールがあるのか「メタ文字」

- 行頭 → ^
- 行末 → \$
- 空白行 → ^\$
- ・該当データ置換 → s/正規表現/置換後/g

• onigsed.exe —e "s/^\$/空/g" foo.txt | more

Onigsedで → テキストー括操作 「g」フラグは2個目以降も置換する

・該当データ置換 → s/正規表現/置換後/g

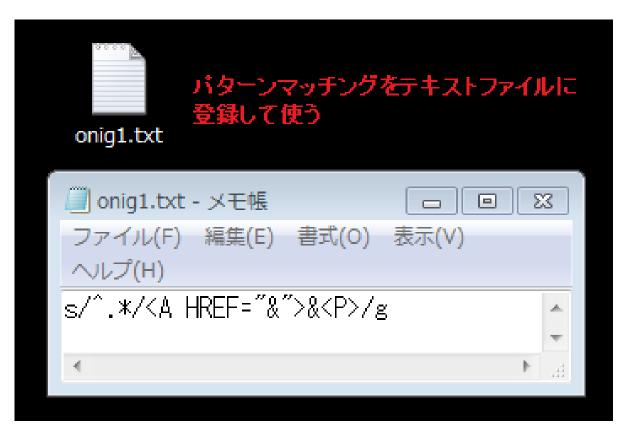
```
J:¥>onigsed.exe -e "s/o/p/" test.txt
J:¥fpo.txt ←最初に見つけた1個だけ置換
J:¥fpo2.txt
J:¥fpo3.txt
J:¥fpo4.txt
IJ:¥test.txt
J:¥>onigsed.exe -e "s/o/p/g" test.txt
J:¥fpp.txt ←2個目以降も置換するのが
J:¥fpp2.txt  【 g 】フラグ
J:¥fpp3.txt
J:¥fpp4.txt
IJ:¥test.txt
```

Onigsedで→テキストー括操作 【 " 】をパターン内で使えないエラー

• 行全体を置換 s/^.*/&<P>/g

Onigsedで→テキストー括操作 対策:外部ファイルに記述しておく

行全体を置換 s/^.*/&<P>/g



Onigsedで→テキストー括操作 onigsed.exe –f 使用ファイル名

行全体を置換s/^.*/&<P>/g

```
J:¥>onigsed.exe -f onig1.txt test.txt
<A HREF="J:\foo.txt">J:\foo.txt<P>
|KA_HREF="J:\foo2.txt">J:\foo2.txt<P>
KA HREF="J:¥foo3.txt">J:¥foo3.txt<P>
KA HREF="J:\foo4.txt">J:\foo4.txt<P>
KA HREF="J:\test.txt">J:\test.txt<P>
```

Onigsedで→テキストー括操作 全行に対して一括処理

全行に改行を追加する置換 s/^.*/&¥n/

```
J:¥>onigsed.exe -e "s/^.*/&¥n/" test.txt
J:¥foo.txt
IJ:¥foo2.txt
IJ:¥foo3.txt
J:¥foo4.txt
J:¥test.txt
```

メタ文字の【*】は直前文字に O回以上繰り返された文字列にマッチ

/Go*gle/

```
マッチする
O回以上にマッチ → Ggle
1回以上にマッチ → Gogle
```

マッチしない Gpgle Gopgle

• 出典元 http://www.rubylife.jp/regexp/repeat/index2.html

メタ文字の【 + 】は 直前文字に1回以上マッチ

/Go+gle/

マッチする Gogle Google

マッチしない Ggle Gopgle

• 出典元 http://www.rubylife.jp/regexp/repeat/index3.html

メタ文字の【 . 】は 改行を除く、任意の一文字にマッチ

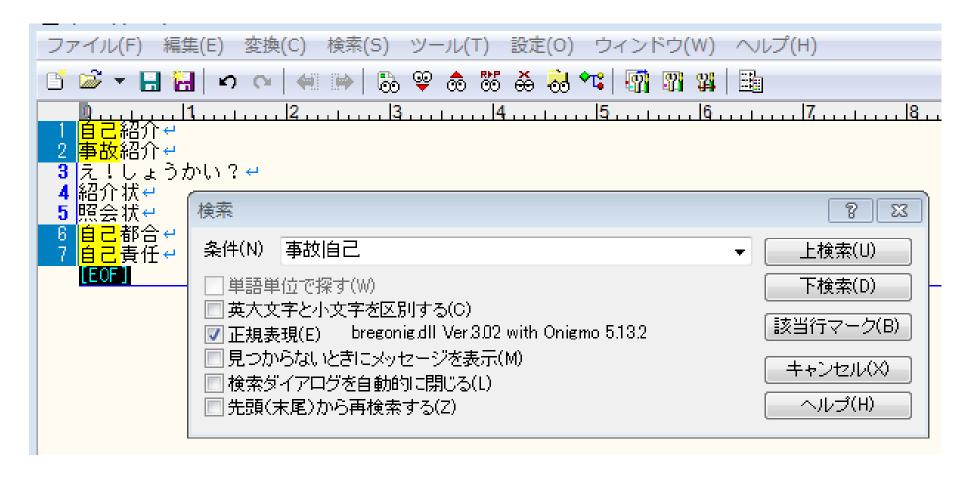
/ab.cd/

マッチする abhcd ab4cd

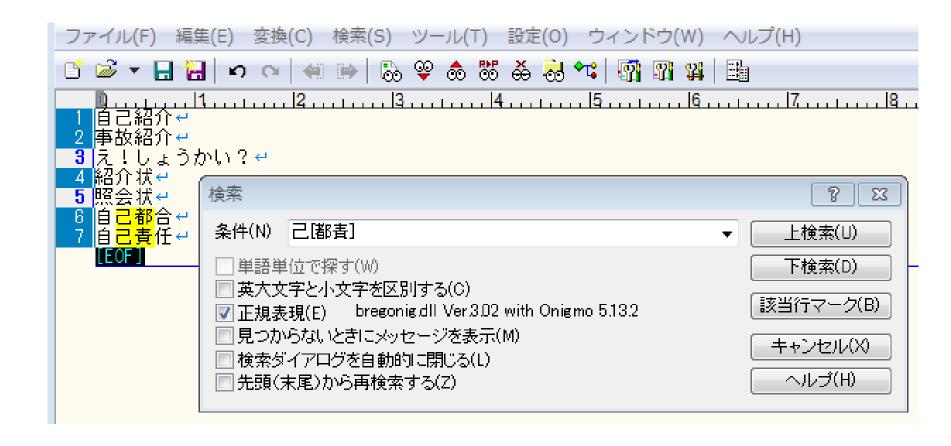
マッチしない abcd abppcd

• 出典元 http://www.rubylife.jp/regexp/repeat/index1.html

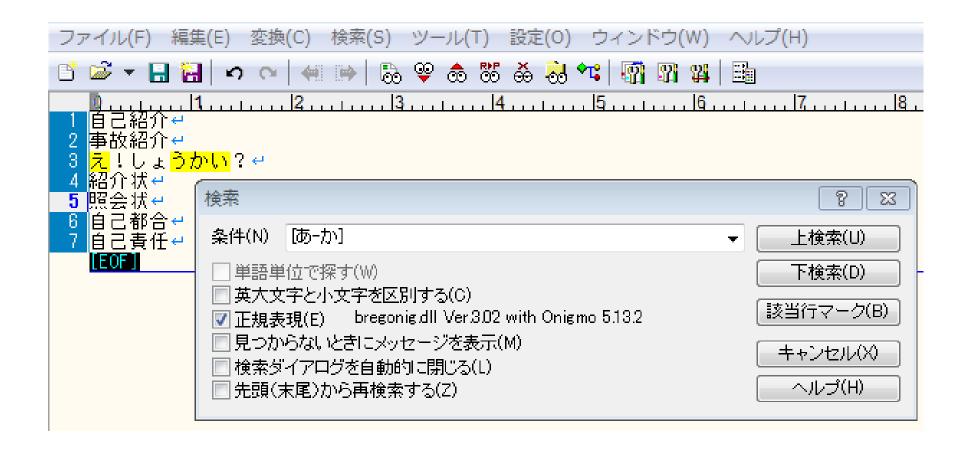
事故|自己 (どちらか)



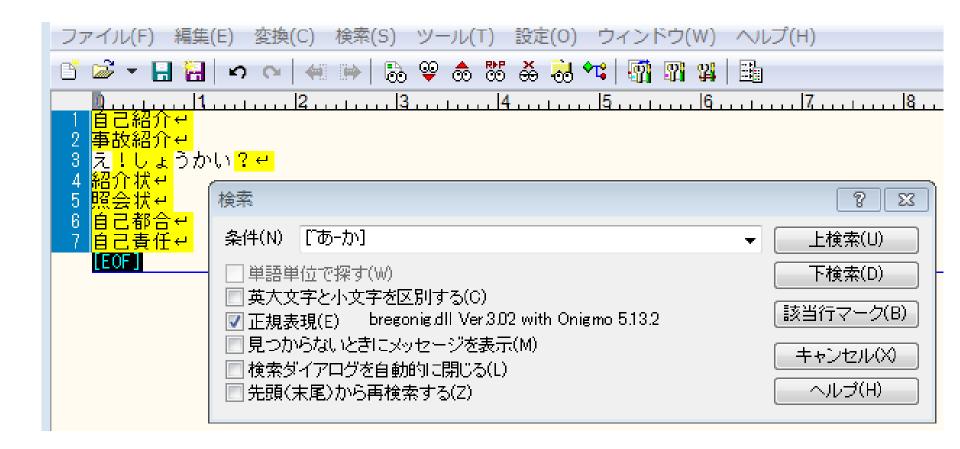
己[都責] (都か責のどれか)



[あ-か] (あ~か迄)



[^あ-か] (あ~か迄以外)



失敗しない為には

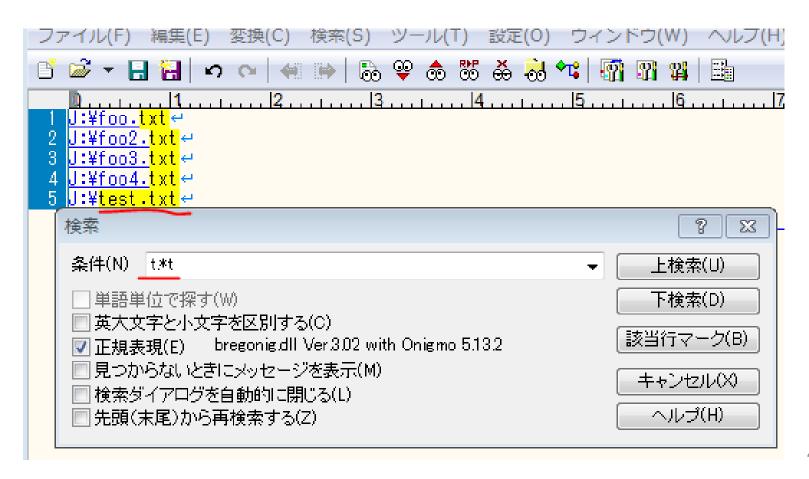
- 複数の抽出条件を指定して絞り込みたい時↓
- 1つの条件で絞り込んだ結果をファイルへ保存する

 \downarrow

・ 保存したファイルを使いまた絞り込む

正規表現の基本は【最長一致】

t.*t → test.txt(最後のtにマッチ)



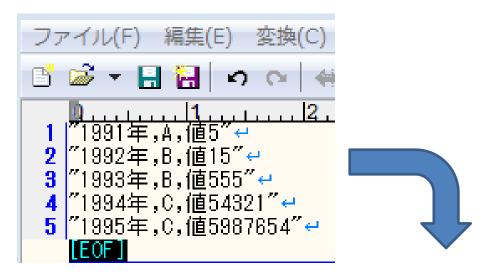
基本動作【最長一致】 最後の 8 にマッチ



【最短一致】は → ? を付加 最初の 8 にマッチ

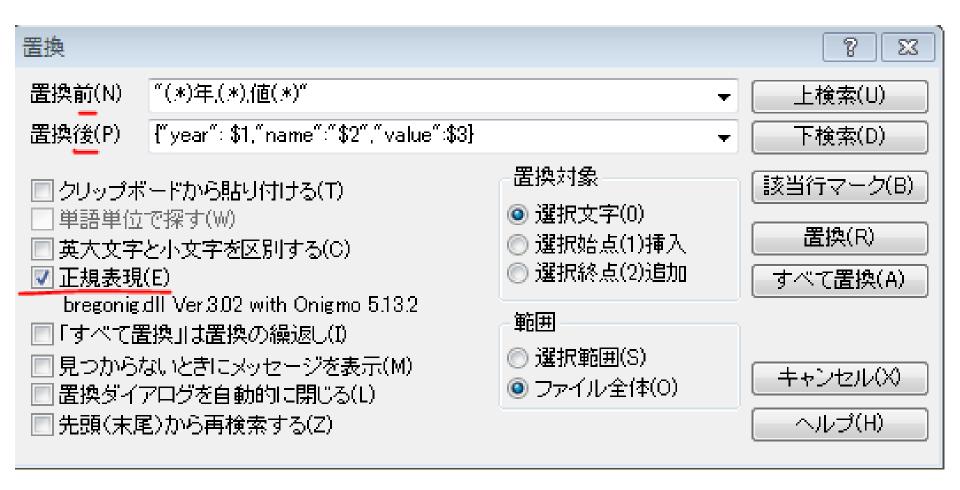
	<u> </u>		14	111111111111111111111111111111111111111	111111411111111111111111111111111111111	سنب	11/11/11/11/19/11	
_1	4							
	67626:201		0:28		opboxUpdate.log-2015			
	67627:201		0:28		opboxUpdate.log-2015			
			0:28		opboxUpdate.log-2015			
	67629:201		<mark>1:28</mark>		opboxUpdate.log-2015			
	67630:201		<mark>2:28</mark>		opboxUpdate.log-2015			
	67631:201		<mark>3:28</mark>		opboxUpdate.log-2015			
	67632:201		<mark>4:28</mark>		opboxUpdate.log-2015			
	67633:201		<mark>5:28</mark>		opboxUpdate.log-2015			
10	67634:201		<mark>5:28</mark>		opboxUpdate.log-2015			
11	67635:201		<mark>5:28</mark>	3,526 Dr	opboxUpdate.log-2015	5-11-2	25-20-28-47-021-	1888-finished
12	67636:201		<mark>6:28</mark>		opboxUpdate.log-2015			
13	67637:201		<mark>7:28</mark>		opboxUpdate.log-2015			
	67638:201		8:28		opboxUpdate.log-2015			
			9:28		opboxUpdate.log-2015			
	67640:201		<mark>0:28</mark>		opboxUpdate.log-2015			
17	67641:201		0:28		opboxUpdate.log-2015			
	67642:201		0:28		opboxUpdate.log-2015			
19	67643:201	5/11/26 1	<mark>1:28</mark>	22,818 Dr	opboxUpdate.log-2015	5-11-2	6-02-28-00-270-	9632-finished←
20	67644:201	5/11/26 1:	<mark>2:28</mark>	20,762 Dr	opboxUpdate.log-2015	5-11-2	6-03-28-00-285-	8148-finished <mark>(EOF)</mark>
		置換					? X	
		置換 置換前(N)	^*?8			-	?	
		置換前(N)				•	上検索(U)	
			^.*?8 ¥t			•		
		置換前(N) 置換後(P)	¥t			*	上検索(U) 下検索(D)	
		置換前(N) 置換後(P)	¥t ボードから貼り付ける	5(T)	置換対象	•	上検索(U)	
		置換前(N) 置換後(P)	¥t	5(T)	◎ 選択文字(0)	• •	上検索(U) 下検索(D) 「該当行マーク(B)	
		置換前(N) 置換後(P) 回 クリップ:	¥t ボードから貼り付ける 立で探す(W)			*	上検索(U) 下検索(D)	
		置換前(N) 置換後(P) 回クリップ: 回車語単位 回英大文等	¥t ボードから貼り付ける 立で探す(W) をと小文字を区別する		◎ 選択文字(0)	-	上検索(U) 下検索(D) 該当行マーク(B) 置換(R)	
		置換前(N) 置換後(P) 回クリップ: 単語単位 一英大文等	¥t ボードから貼り付ける 立で探す(W) 客と小文字を区別する 見(E)	3(C)	選択文字(0)選択始点(1)挿入選択終点(2)追加	-	上検索(U) 下検索(D) 「該当行マーク(B)	
		置換前(N) 置換後(P) 回クリップ: 単語単位 可英大文字 図正規表取 bregonia	¥t ボードから貼り付ける 立で探す(W) Pと小文字を区別する 見(E) gdll Ver302 with Or	る(C) nigmo 5.13.2	選択文字(0)選択始点(1)挿入	-	上検索(U) 下検索(D) 該当行マーク(B) 置換(R)	
		置換前(N) 置換後(P) 回クリップ: 単語単位 一英大文等 「必正規表現 bregonii	¥t ボードから貼り付ける 立で探す(W) をと小文字を区別する 見(E) gdll Ver302 with Oi 置換』は置換の繰返	る(C) nigmo 5.13.2 む(I)	選択文字(0)選択始点(1)挿入選択終点(2)追加	-	上検索(U) 下検索(D) 該当行マーク(B) 置換(R)	
		置換前(N) 置換後(P)	¥t ボードから貼り付ける 立で探す(W) Pと小文字を区別する 見(E) gdll Ver3.02 with Oi 置換』は置換の繰返 がないときにメッセージ	る(C) nigmo 5.13.2 {し(I) ジを表示(M)	選択文字(0)選択始点(1)挿入選択終点(2)追加範囲選択範囲(S)	-	上検索(U) 下検索(D) 該当行マーク(B) 置換(R) すべて置換(A)	
		置換前(N) 置換後(P)	¥t ボードから貼り付ける 立で探す(W) をと小文字を区別する 見(E) gdll Ver302 with Oi 置換』は置換の繰返	る(C) nigmo 5.13.2 {し(I) ジを表示(M)	選択文字(0)選択始点(1)挿入選択終点(2)追加	-	上検索(U) 下検索(D) 下検索(D) 該当行マーク(B) 置換(R) すべて置換(A)	
		置換前(N) 置換後(P)	¥t ボードから貼り付ける 立で探す(W) Pと小文字を区別する 見(E) gdll Ver3.02 with Oi 置換』は置換の繰返 がないときにメッセージ	る(C) nigmo 5.13.2 む(I) ジを表示(M) 肌じる(L)	選択文字(0)選択始点(1)挿入選択終点(2)追加範囲選択範囲(S)	-	上検索(U) 下検索(D) 該当行マーク(B) 置換(R) すべて置換(A)	

一括でフォーマットを変更(置換)





() → は値をグループ化\$1 → は最初のグループ化の値



【実現したいこと】 青文字部分だけを取り出して → フォーマットを変える

```
"1991年,A,値 5" というデータを → {"year": 1991, "name": "A", "value": 5} にしたい
```

【置換前】 取り出したい青文字部分を () で囲みグループ化する(赤文字がデータ区切り記号になる) "(.*)年,(.*),値(.*)"

【置換後】 グループ化した青文字データを使い新しいフォーマットに変更する {"year": \$1,"name":"\$2","value":\$3}

【応用例】

{"value":\$3:\$1:\$2"}

